



Analyse du risque de défaut de paiement des emprunteurs

Home Credit Default Risk · Kaggle

Tagba Abide | Data Analyst

**CONTEXTE**

Home Credit Group accorde des crédits à des emprunteurs peu bancarisés, sans historique de crédit formel. La maîtrise du risque de défaut est cruciale pour réduire les pertes financières.

307 511

Observations

**OBJECTIF**

Réaliser une analyse exploratoire (EDA) pour identifier les facteurs associés au défaut de paiement et préparer la modélisation prédictive.

122

Variables

91,9 %

Sans défaut

**DATASET**

307 511 observations

122 variables

Variable cible : TARGET


(0 = Pas de défaut · 1 = Défaut)

Source : Kaggle – Home Credit

8,1 %

Taux de défaut

DISTRIBUTION DE LA VARIABLE CIBLE (TARGET)



QUALITÉ DES DONNÉES

Observations totales	307 511
----------------------	---------

Variables	122
-----------	-----

Valeurs manquantes moy.	18,4 %
-------------------------	--------

Colonnes avec nulls	67 / 122
---------------------	----------

Doublons	0
----------	---


Déséquilibre des classes	91 / 9
--------------------------	--------



Déséquilibre marqué : seulement 8,1 % de défauts — nécessite des techniques d'équilibrage (SMOTE, pondération) avant modélisation.

LES VARIABLES FINANCIÈRES EXPLIQUENT-ELLES LE RISQUE DE DÉFAUT ?

Exemple : montant du crédit selon le statut de remboursement.



ENSEIGNEMENTS CLÉS

**Distributions similaires**

Les montants de crédit se recouvrent fortement entre les deux groupes — pas de séparation nette.

**Valeurs extrêmes présentes**

Des crédits élevés existent aussi bien chez les clients en défaut que chez ceux sans défaut.


**Variable insuffisante seule**

Le montant du crédit ne permet pas d'expliquer le risque de défaut sans être combiné à d'autres caractéristiques des emprunteurs.


TAUX DE DÉFAUT SELON LE SEXE




TAUX DE DÉFAUT SELON LE NIVEAU D'ÉTUDES



TAUX DE DÉFAUT SELON LA PROFESSION



TAUX DE DÉFAUT SELON LE TYPE DE LOGEMENT



► Les hommes, les professions peu qualifiées (Low-skill Laborers) et les locataires présentent les taux de défaut les plus élevés.

Variable analysée	Observation principale	Interprétation métier
Sexe	Les hommes présentent un taux de défaut plus élevé que les femmes.	Le sexe semble être associé au risque de défaut dans ce jeu de données.
Type de revenu	Les salariés présentent un taux plus élevé que les retraités et fonctionnaires.	La stabilité de la source de revenu influence la capacité de remboursement.
Niveau d'études	Le niveau d'études : le risque de défaut diminue globalement lorsqu'il augmente.	Le niveau d'études est un indicateur pertinent du profil de risque.
Situation familiale	Les célibataires et personnes en union civile ont des taux plus élevés que les personnes mariées.	La situation familiale semble influencer le comportement de remboursement.
Type de logement	Les locataires et personnes chez leurs parents présentent les taux les plus élevés.	Une plus grande stabilité résidentielle est associée à un risque plus faible.
Profession	Les métiers peu qualifiés présentent les taux de défaut les plus élevés, tandis que les professions qualifiées affichent des taux plus faibles.	La profession est l'un des facteurs les plus discriminants du risque de crédit.



Feature Engineering

Créer des ratios income/credit, encoder les variables catégorielles, exploiter EXT_SOURCE.



Équilibrage des classes

Appliquer SMOTE ou pondération pour compenser le déséquilibre 91 / 9.



Segmentation par profession

Intégrer la catégorie professionnelle comme variable de risque dans les règles d'octroi.



Prise en compte du niveau d'études

Intégrer le niveau d'études dans l'évaluation du risque afin d'améliorer la qualité des décisions d'octroi de crédit.



Qualité des données

Automatiser l'imputation des 67 colonnes à valeurs manquantes avant mise en production.



Modèle prédictif ML

Déployer un modèle gradient boosting (LightGBM/XGBoost) guidé par les enseignements EDA.

CONCLUSION & PERSPECTIVES



ENSEIGNEMENTS CLÉS

- Déséquilibre des classes (91/9) à traiter
- Les variables socio-économiques apparaissent plus discriminantes que les variables financières étudiées individuellement.
- La profession et le niveau d'études apparaissent comme les variables les plus discriminantes.
- Locataires et hommes = profils plus risqués



LIMITES DE L'ANALYSE

- L'EDA ne confirme pas la causalité
- Valeurs manquantes dans colonnes clés
- Analyse sur une seule table principale
- Le déséquilibre biaise certaines statistiques



PERSPECTIVES

- Feature Engineering avancé
- Machine Learning (LightGBM, XGBoost)
- Modèles de scoring de crédit (Scorecard)
- Déploiement & scoring en temps réel